

MECANIQA — COMPREENSÃO E BASELINE PREDITIVO

Autores: Alex Oliveira Santos
Alice Gomes Aragão
Ana Clara Ribeiro da Silva
Lorran Edley Matos Ribeiro
Rodrigo dos Anjos Lamartine

Agenda

O objetivo dessa apresentação é demonstrar a compreensão de séries temporais e a criação de um baseline preditivo.

1. Item: Contexto do Problema

Oficinas mecânicas sofrem com picos inesperados de demanda, falta de peças e ociosidade de mecânicos.

2. Item: Objetivo

Criar um modelo baseline para prever a demanda de Trocas de Óleo e Manutenções de Motor.

3. Item: Dataset

- 731 registros (01/01/2024 a 31/12/2025)
- 6 valores ausentes em Trocas_Oleo
- 3 valores ausentes em Manutencao_Motor

4. Item: Metodologia

Decomposição aditiva ($Y = T + S + R$)
Janela de 7 dias (sazonalidade semanal)

5. Item: Resultados

Tratamento de outliers (IQR); decomposição em 4 componentes; avaliação dos modelos baseline (MAE/RMSE)

Contexto do Problema



Oficinas MecaniQA enfrentam desafios como:

- Picos inesperados de demanda
- Falta de peças em períodos de maior movimento
- Ociosidade dos mecânicos em períodos de baixa demanda

Objetivo do problema: melhorar o planejamento dos serviços da oficina.

Objetivo



Criar um modelo baseline capaz de prever a demanda de serviços da oficina.

Serviços analisados:

- Trocas de Óleo
- Manutenções de Motor

O modelo servirá como referência para futuras previsões mais avançadas.

Dataset



731 registros | Período: 01/01/2024 a 31/12/2025


- 731 dias consecutivos; 0 dias inteiros sem registro
- Valores ausentes:
 - 6 em Trocas_Oleo
 - 3 em Manutencao_Motor
- Os dados foram organizados cronologicamente antes da análise.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	Data	Trocas_Oleo	Manutencao_Motor															
2	2024-01-01	11.0	2.0															
3	2024-01-02	9.0	4.0															
4	2024-01-03	12.0	1.0															
5	2024-01-04	15.0	8.0															
6	2024-01-05	25.0	10.0															
7	2024-01-06	25.0	10.0															
8	2024-01-07	31.0	14.0															
9	2024-01-08	13.0	8.0															
10	2024-01-09	10.0	6.0															
11	2024-01-10	13.0	1.0															
12	2024-01-11	10.0	1.0															
13	2024-01-12	26.0	8.0															
14	2024-01-13	28.0	11.0															
15	2024-01-14	22.0	9.0															
16	2024-01-15	7.0	1.0															
17	2024-01-16	11.0	4.0															
18	2024-01-17	10.0	2.0															
19	2024-01-18	14.0	4.0															
20	2024-01-19	25.0	7.0															
21	2024-01-20	24.0	7.0															
22	2024-01-21	33.0	10.0															
23	2024-01-22	13.0	3.0															
24	2024-01-23	14.0	7.0															
25	2024-01-24	10.0	2.0															
26	2024-01-25	13.0	10.0															
27	2024-01-26	30.0	12.0															
28	2024-01-27	26.0	10.0															
29	2024-01-28	11.0	10.0															

Tratamento de Dados

- Ausentes: interpolação temporal — 6 em Trocas_Oleo e 3 em Manutencao_Motor.
- Inválidos: 5 valores negativos em Manutencao_Motor — convertidos em NaN e interpolados.
- IQR: 150 trocas de óleo (15/02/2024), 85 manutenções (19/07/2024) e 24 (03/05/2025).
- Correção: clipping nos limites do IQR, preservando a continuidade da série.

Tratamento do outlier — Trocas de Óleo (15/02/2024)



Metodologia

Foi utilizada a decomposição aditiva:

$$Y = T + S + R$$

- **T — Tendência:** comportamento geral da série
- **S — Sazonalidade:** padrões que se repetem
- **R — Resíduo:** variações não explicadas

```
12
13 resultado = seasonal_decompose(
14     df["Trocas_Oleo"],
15     model="additive",
16     period=7
17 )
```

Janela de 7 dias


Representa a **sazonalidade semanal**.

Metodologia

A série temporal foi decomposta em 4 componentes:

- Série Observada
- Tendência
- Sazonalidade
- Resíduos


Também foram implementados modelos baseline para previsão da demanda.



Resultados

- Avaliação dos 3 modelos baseline (últimos 30 dias como teste), por MAE e RMSE:

Variável	Modelo	MAE	RMSE
Trocas de Óleo	Naive ✓	6,40	8,73
	Média Móvel 7d	7,07	7,75
	Média Móvel 30d	6,67	7,93
Manutenção de Motor	Naive	3,50	4,51
	Média Móvel 7d ✓	3,22	3,73
	Média Móvel 30d	3,26	3,80



✓ = menor MAE. Em Trocas de Óleo, o Naive teve o menor MAE (6,40), mas a Média Móvel 7d teve o menor RMSE (7,75). Em Manutenção de Motor, a Média Móvel 7d foi a melhor nos dois indicadores.

Considerações finais



A análise revelou tendência de crescimento e sazonalidade semanal, enquanto os modelos baseline estabeleceram uma referência objetiva para avaliar futuras previsões de Machine Learning.

Referências



- Documentação Pandas — pandas.pydata.org
- Documentação Statsmodels — statsmodels.org
- Caderno de Guias — OAT 1