

BASELINE E MÉTRICAS DE AVALIAÇÃO

Autores: Alex Oliveira Santos
Alice Gomes Aragão
Ana Clara Ribeiro da Silva
Lorran Edley Matos Ribeiro
Rodrigo dos Anjos Lamartine

Agenda

Nesta apresentação, avaliamos o baseline da OAT 1 com métricas de erro e validação temporal robusta.

1. Item: Contexto

O baseline já existe — falta medir seu erro real.

4. Item: Validação Temporal

Substituir a validação aleatória pelo `TimeSeriesSplit`.

2. Item: Objetivo

Validar Naive e Média Móvel com métricas de erro.

5. Item: Resultados

Apresentar as métricas finais e as novas features.

3. Item: Anti Leakage

Garantir que nenhuma previsão usa dados do futuro.

Contexto do Problema



Na OAT 1, criamos os primeiros baselines: Naive e Médias Móveis.

Mas um baseline só tem valor se soubermos o quanto ele erra.

Nesta etapa, avaliamos esse baseline com rigor e sem vazamento de dados.

Objetivo



Avaliar os modelos Naive e Média Móvel com MAE, RMSE e MAPE.

Confirmar, com QA automatizado, que não há vazamento de dados.

Substituir a validação aleatória pelo TimeSeriesSplit.

Criar Lags e Rolling Windows para os próximos modelos.

Dataset Já Limpo



O dataset tem 731 registros, de 01/01/2024 a 31/12/2025.

Reaplicamos o pipeline de limpeza da OAT 1: valores negativos viram NaN e são interpolados; outliers são tratados por clipping (método IQR).

Assim, todo o baseline roda sobre dados já tratados.

```
Formato do dataset limpo: (731, 2)
Valores ausentes após limpeza:
Trocas_Oleo      0
Manutencao_Motor 0
dtype: int64
```

[2]:

	Trocas_Oleo	Manutencao_Motor
Data		
2024-01-01	11.0	2.0
2024-01-02	9.0	4.0
2024-01-03	12.0	1.0
2024-01-04	15.0	8.0
2024-01-05	25.0	10.0


Baseline sem Data Leakage

O Naive usa shift(1): a previsão de hoje é o valor de ontem.

A Média Móvel calcula a média e só depois aplica o shift.

Essa ordem evita que a janela veja o próprio dia atual.

Um QA automatizado confirma que não há vazamento de dados.



Validação Temporal



O K-Fold tradicional embaralha os dias e quebra a cronologia.

O TimeSeriesSplit sempre testa em um período após o treino.

Usamos 5 folds cronológicos, avaliados por MAE, RMSE e MAPE.

O MAPE só considera os dias com demanda maior que zero.

```
=====
=== Trocas_Oleo - Validação Temporal (TimeSeriesSplit, 5 folds) ===
=====
```

Modelo Naive - por fold:

fold	período_teste	n_dias	MAE	RMSE	MAPE	dias_excluidos_mape
1	2024-05-06 a 2024-09-03	121	6.867769	9.074986	42.549639	0
2	2024-09-04 a 2025-01-02	121	6.611570	9.074531	51.021833	1
3	2025-01-03 a 2025-05-03	121	6.371901	8.333444	18.954565	0
4	2025-05-04 a 2025-09-01	121	6.702479	9.027506	23.104419	0
5	2025-09-02 a 2025-12-31	121	6.677686	9.081814	27.582173	0

Resultados do Baseline - MAE: 6.65, RMSE: 8.92, MAPE: 32.64%

Modelo Média Móvel 7d - por fold:

Resultados Comparativos

Para Trocas de Óleo, o Naive teve o menor erro (MAE 6,65).

Para Manutenção de Motor, a Média Móvel 7d venceu (MAE 3,19).

O RMSE ficou mais alto que o MAE nas duas variáveis.

Isso mostra que os picos de demanda ainda pesam.

Esses números são o novo piso de comparação para o ML.

[8]:

	Variável	Modelo	MAE	RMSE	MAPE
0	Trocas_Oleo	Naive	6.646281	8.918456	32.642526
1	Trocas_Oleo	Média Móvel 7d	7.355844	8.088136	37.218204
2	Manutencao_Motor	Naive	3.365289	4.360702	42.388327
3	Manutencao_Motor	Média Móvel 7d	3.190634	3.788077	43.788731

Feature Engineering Temporal



Criamos Lags de 1, 7 e 30 dias para as duas variáveis.

O Lag 7 é o mais importante: capta o padrão semanal.

A Rolling Window de 7 dias também virou um atributo fixo.

Descartamos as 30 primeiras linhas, geradas pelo Lag 30.

Data	Taxas_Obr	Mantenedores_Motor	Taxas_Obr_lag_1	Taxas_Obr_lag_7	Taxas_Obr_lag_30	Mantenedores_Motor_lag_1	Mantenedores_Motor_lag_7	Mantenedores_Motor_lag_30	Taxas_Obr_rolling_mean_7	Mantenedores_Motor_rolling_mean_7
2004-01-01	1407	37	1407	955	117	37	37	37	19.07123	7.71439
2004-02-01	3719	100	1407	1107	907	37	37	37	20.10207	8.10207
2004-03-01	3719	100	670	300	107	100	100	100	21.08714	8.07143
2004-04-01	1819	109	670	300	100	100	100	100	21.40971	9.07143
2004-05-01	307	100	300	110	230	100	100	100	21.71439	9.00000
2004-06-01	100	30	300	100	100	100	100	100	22.14007	9.00714
2004-07-01	100	100	100	100	100	100	100	100	22.10007	9.00000
2004-08-01	100	100	100	100	100	100	100	100	22.07143	10.00000
2004-09-01	100	100	100	100	100	100	100	100	22.10007	9.71439
2004-10-01	100	100	100	100	100	100	100	100	22.00000	9.00000
2004-11-01	100	100	100	100	100	100	100	100	22.00714	8.00714
2004-12-01	100	100	100	100	100	100	100	100	22.00007	9.00000
2004-01-01	100	100	100	100	100	100	100	100	22.00000	9.00000
2004-02-01	100	100	100	100	100	100	100	100	22.07143	8.07143
2004-03-01	100	100	100	100	100	100	100	100	22.07143	9.07143

Considerações finais



O baseline da OAT 1 foi avaliado com MAE, RMSE e MAPE.

O TimeSeriesSplit confirmou que não houve vazamento de dados.

O Naive venceu em Óleo; a Média Móvel venceu em Motor.

O dataset está pronto, com Lags e Rolling Window, para o ML.

Referências



- Documentação Pandas — pandas.pydata.org
- Documentação scikit-learn — scikit-learn.org
- Caderno de Guias — OAT 1 e OAT 2